第一章 引论

许畅

南京大学计算机系

2017年春季

课程概要 (1)

- 课程教材：《编译原理》(“龙书”)
- 实验教材：《编译原理实践与指导教程》
- 讲课老师：许畅 (changxu@nju.edu.cn)
- 课程网站：http://cs.nju.edu.cn/changxu/主页下
- 授课时段：18周 (72学时)
- 授课安排：周三5–6节、周五5–6节
- 授课地点：仙II-306
- 课程助教：王慧妍 (实验)、郭冰莹 (作业)

课程概要 (2)

- 课程意义
  - 计算机专业的**必选课** (3学分)
  - 学习编译器设计的原理和程序分析的技术
  - 研究生技能需求 (与计算机科学、软件技术、信息安全、计算机系统、计算机应用等专业方向相关)
  - 成为高手的必要一步 (编程大师、黑客等)

- 课程结构
  - 理论部分：上课听讲，下课作业，交书面作业
  - 实践部分：实现编译器的几个阶段，交上机实验

课程概要 (3)

- 评分标准
  - 书面作业：10% (20% + 20% + 60%)
  - 上机实验：30% (20% + 20% + 60%)
    - 组队调整：110% (1人)，100–105% (2人)，90–95% (3人)
    - 额外奖励：编译效率PK、对实验的帮助等
    - 实验内容：随机 (普通班)，所有 (基础班)
  - 期末考试：60%

  - 不可控因素：系里点名、作弊检查等

课程概要 (4)

- 特别说明

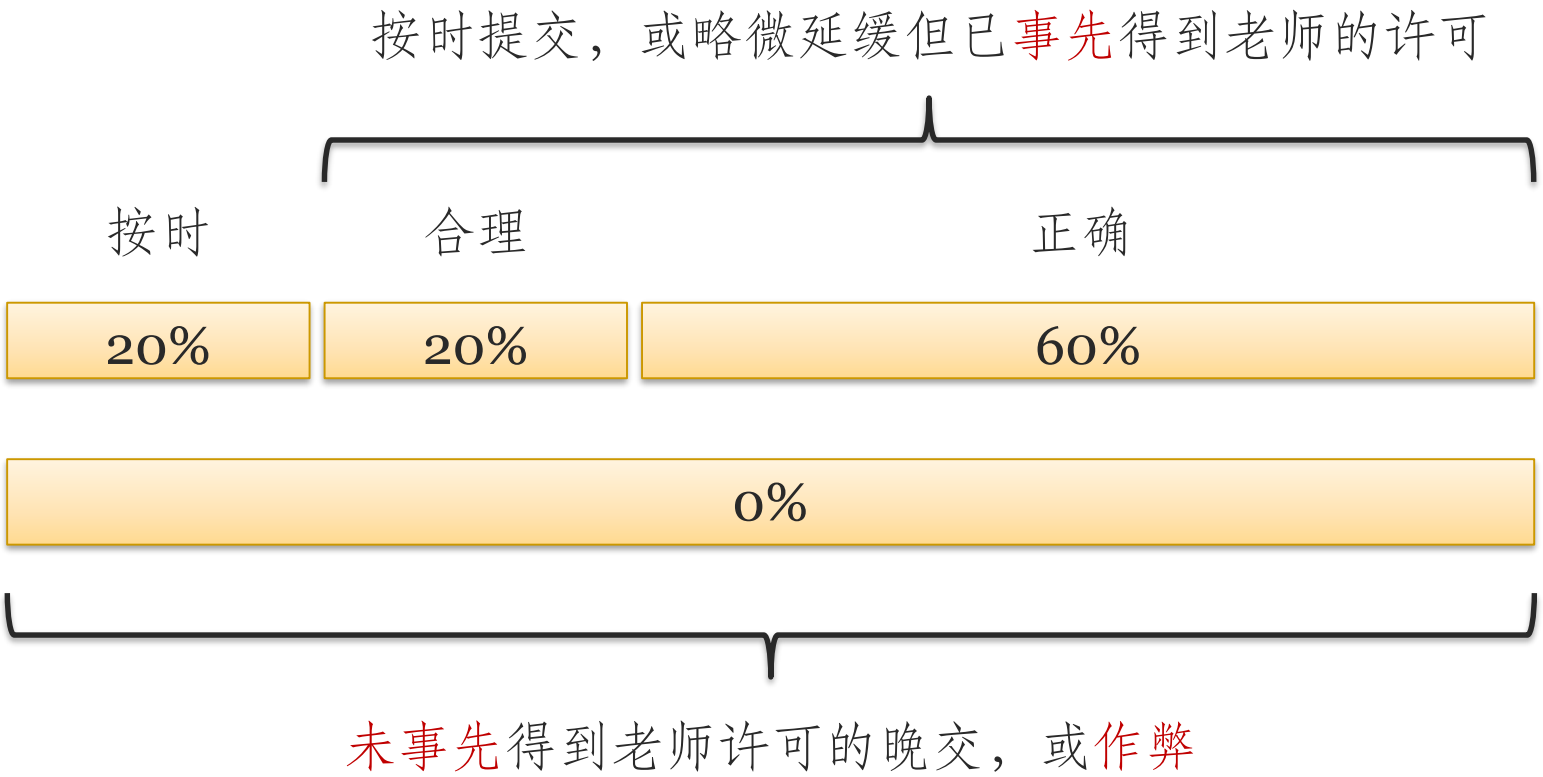

事先：提交截止时间前24小时

课程内容

- 1. 引论 (易)
- 3. 词法分析 (难)
- 4. 语法分析 (难)

安排较紧

- 5. 语法制导的翻译技术 (中)
- 6. 中间代码生成 (难)
- 7. 运行时刻环境 (易)
- 8. 代码生成 (中)
- 9. 机器无关优化 (中)

安排较松

编译器的作用

- 编译器
  - 读入以某种语言(源语言)编写的程序
  - 输出等价的用另一种语言(目标语言)编写的程序
  - 通常目标程序是可执行的

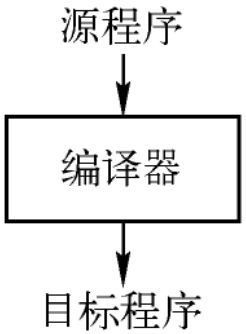

- 解释器
  - 直接利用用户提供的输入，执行源程序中指定的操作
  - 不生成目标程序，而是根据源程序的语义直接运行
  - Java语言的处理结合了编译和解释

编译器的结构 (1)

- 编译器可以分为**分析**部分和**综合**部分
- 分析部分 (**前端**/Front end)
  - 把源程序分解成组成要素，以及相应的语法结构
  - 使用这个结构创建源程序的中间表示
  - 同时收集和源程序相关的信息，存放到**符号表**
- 综合部分 (**后端**/Back end)
  - 根据中间表示和符号表信息构造目标程序

- 前端部分是**机器无关**的，后端部分是**机器相关**的

编译器的结构 (2)

- 编译器可分成顺序执行的一组**步骤** (Phases)

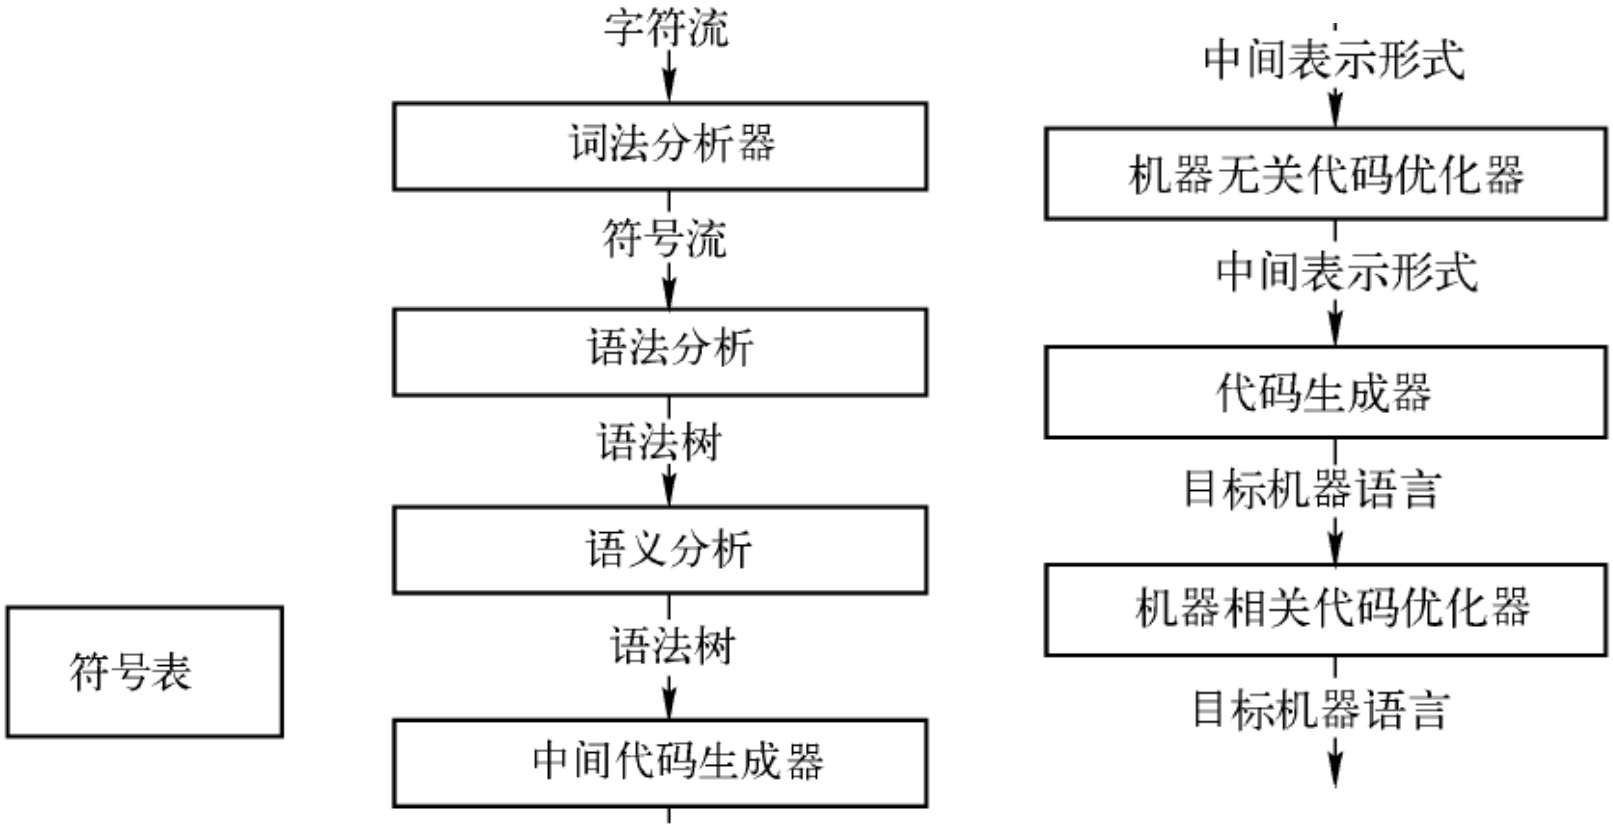

词法分析

- **词法分析/扫描** (Lexical analysis/scanning)
  - 读入源程序的字符流，输出为有意义的**词素** (Lexeme)
  - <token-name, attribute-value>
  - token-name由语法分析步骤使用
  - attribute-value指向相应的符号表条目，由语义分析/代码生成步骤使用
- 例子
  - position = initial + rate * 60
  - <id, 1> <=, > <id, 2> <+, > <id, 3> <*, > <number, 4>

语法分析

- **语法分析/解析** (Syntax analysis/parsing)
  - 根据各个词法单元的第一个分量来创建树型的中间表示形式，通常是**语法树** (Syntax tree)
  - 中间表示形式指出了词法单元流的语法结构

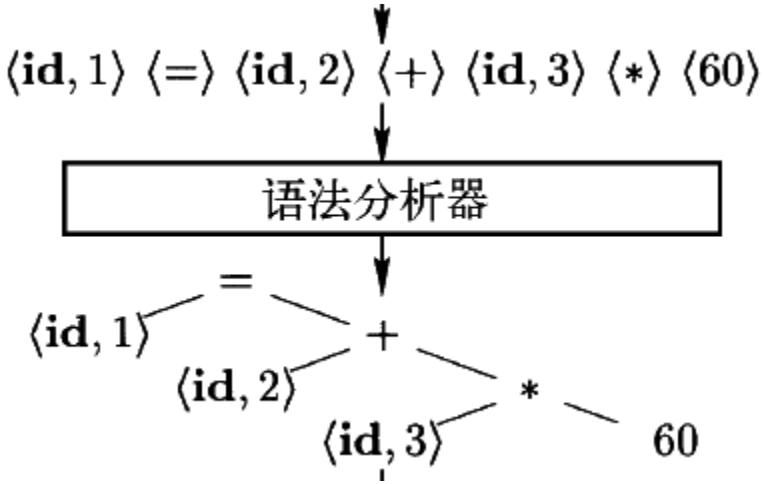

语义分析

- 语义分析 (Semantic analysis)
  - 使用语法树和符号表中的信息，检查源程序是否满足语言定义的语义约束
  - 同时收集类型信息，用于代码生成、类型检查、类型转换

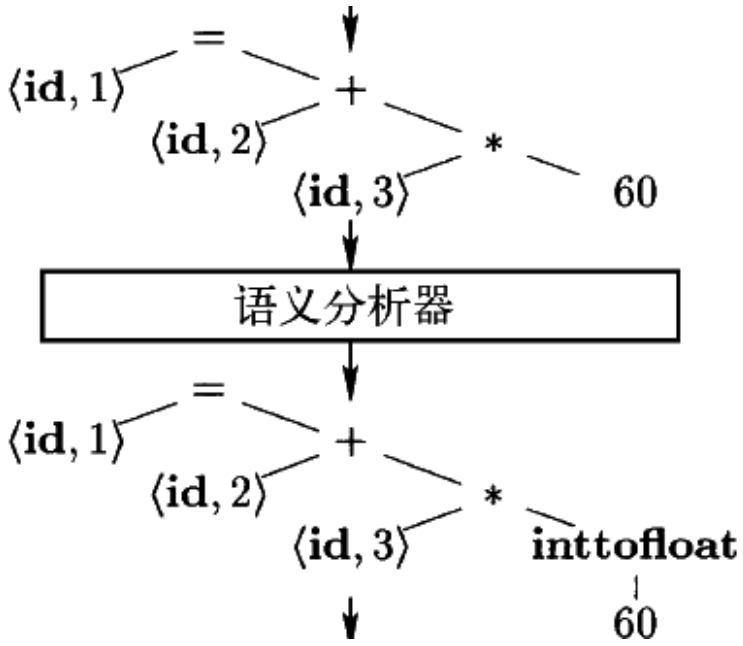

中间代码生成

- 根据语义分析输出，生成类机器语言的中间表示
- **三地址代码**
  - 每个指令最多包含三个运算分量
  - t1 = inttofloat(60); t2 = id3 * t1; t3 = id2 + t2; …
  - 很容易生成机器语言指令

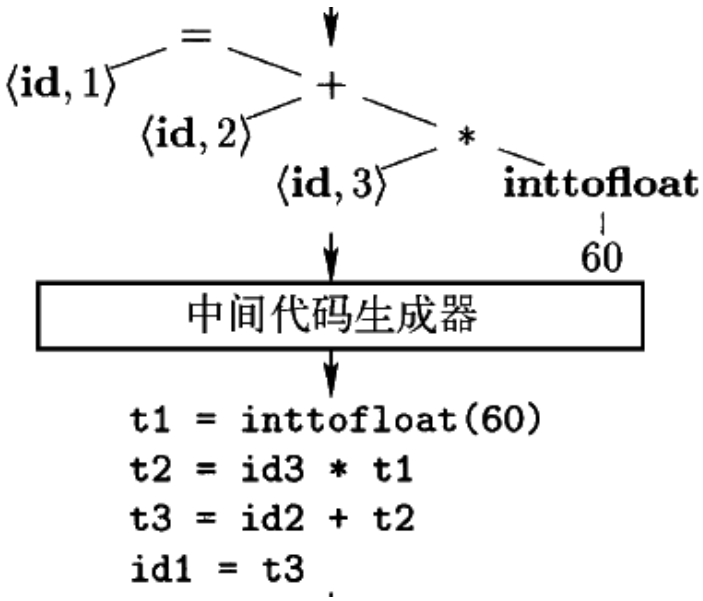

中间代码优化

- 通过对中间代码的分析，改进中间代码的质量
  - 更快、更短、能耗更低

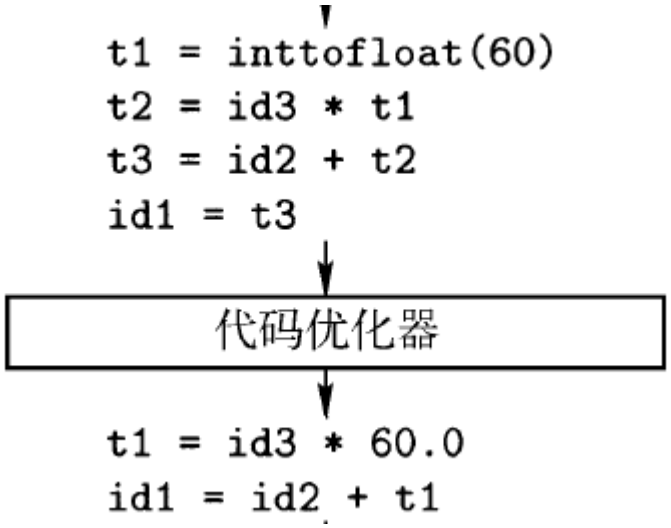

代码生成

- 把中间表示形式映射到目标语言
  - 寄存器的分配
  - 指令选择

```
t1 = id3 * 60.0
id1 = id2 + t1
```

↓

代码生成器

↓

```
LDF  R2, id3
MULF R2, R2, #60.0
LDF  R1, id2
ADDF R1, R1, R2
STF  id1, R1
```

其它概念

- 符号表管理
  - 记录源程序中使用的变量的名字，收集各种属性
- 趟 (Pass)
  - 每趟读入一个输入文件，产生一个输出文件
  - “步骤” (Phase) 是逻辑组织方式
  - “趟”和具体的实现相关
- 编译器构造工具
  - 扫描器 (Lex/Flex)、语法分析器 (Yacc/Bison)、语法制导的翻译引擎、...

程序设计语言的发展历程

- 历程
  - 第一代：机器语言
  - 第二代：汇编语言(宏命令)
  - 第三代：Fortran、Cobol、Lisp、C、C++、...
  - 第四代：特定应用语言NOMAD、SQL、Postscript
  - 第五代：基于逻辑和约束的语言Prolog、OPS5
- **强制式语言/声明式语言**
  - 前者指明如何完成，后者指明要完成哪些计算
- 冯·诺依曼语言/面向对象的语言/脚本语言

语言和编译器之间的关系

- 程序设计语言的新发展向编译器设计者提出新的要求
  - 设计相应的算法和表示方法来翻译和支持新的语言特征，如多态、动态绑定、类、类属(模板)、...
- 通过降低高级语言的执行开销，推动这些高级语言的使用
- 编译器设计者还需要更好地利用新硬件的能力
  - RISC技术、多核技术、大规模并行技术

编译技术的应用 (2)

- 程序翻译
  - 二进制翻译/硬件合成/数据查询解释器/编译后模拟
- 软件生产率工具
  - 类型检查
  - 边界检查 (软件测试)
  - 内存管理工具 (内存泄漏)

程序设计语言的基础概念 (1)

- 静态/动态
  - **静态**：支持编译器静态决定某个问题
  - **动态**：只允许在程序运行时刻作出决定
  - Java类声明中的static指明变量的存放位置可静态确定
- 作用域
  - x的作用域指程序文本的一个区域，其中对x的使用都指向这个声明
  - **静态作用域**：通过静态阅读程序即可决定作用域
  - **动态作用域**

程序设计语言的基础概念 (2)

- 环境与状态
  - 环境：是从名字到存储位置的映射
  - 状态：从存储位置到它们值的映射


```
...
int i;                    /* 全局i          */
...
void f(···) {
      int i;              /* 局部 i         */
      ...
      i = 3;              /* 对局部i的使用*/
      ...
}
...
      x = i + 1;          /* 对全局i 的使用*/
```

图 1-9　名字 i 的两个声明

程序设计语言的基础概念(3)

- 静态作用域和块结构
  - C语言使用静态作用域
    - C语言程序由顶层的变量、函数声明组成
    - 函数内部可以声明变量(局部变量/参数)，这些声明的作用域在它出现的函数内
    - 一个顶层声明的作用域包括其后的所有程序
  - 作用域规则基于程序结构，声明的作用域由它在程序中的位置决定
  - 也通过public、private、protected进行明确控制

程序设计语言的基础概念 (4)

- 块作用域的例子

```
main() {
    int a = 1;                    B1
    int b = 1;
    {
        int b = 2;                B2
        {
            int a = 3;            B3
            cout << a << b;
        }
        {
            int b = 4;            B4
            cout << a << b;
        }
        cout << a << b;
    }
    cout << a << b;
}
```

声　　明	作用域
int a = 1;	$B_1 - B_3$
int b = 1;	$B_1 - B_2$
int b = 2;	$B_2 - B_4$
int a = 3;	B_3
int b = 4;	B_4